序号	算子编号	算子ID（英文）	算子名称	所属产线	对应环节	链路位置	流程是否可跳过	工具类型	基座模型	调外部API	能力说明	处理逻辑	前置依赖	输入数据	输出数据
1	META-OP-01	meta_clean_slice	正文抽取与切片	文本元信息	环节① 文档接入与切片	阶段首 · 第1环	不可跳过（产线固定环节）	规则型	无（标准库 HTMLParser + 正则）	否	把网页存档 HTML 抽取为标题、来源与正文，完成正文有效性校验后按章节→段落切片（单片≤2000字、重叠200字），形成一文档一行的结构化记录，供体裁判定与事实抽取消费。	两级解码（UTF-8 严格 → GB18030 回退）→ HTMLParser 抽取标题/来源/正文并清洗 → 正文校验（空白页、导航页、≥1 段可读文本）→ 章节→段落切片、超长段落硬切 → 写 records.jsonl 与血缘。	平台 uploadFile 上传 HTML/HTM 素材 zip；predict 传 uniqueId	HTML/HTM 文件（zip 或散文件，按文件名升序）；单批 ≤2GB	records.jsonl（docId/fileName/title/source/textLength/sliceCount/slices[{sliceId,index,text,charCount}]）；lineage_<uniqueId>.jsonl
2	META-OP-02	meta_genre_judge	新闻体裁判定	文本元信息	环节① 文档接入与切片（体裁校验）	第2环	不可跳过（产线固定环节）	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	对上游正文做新闻体裁校验：按事件性、时效性、事实性、公共传播性四条标准判定是否新闻，输出体裁类别、四条件、置信度与依据；非新闻在此出局，是文本元信息产线的总闸。	规则粗筛明显非新闻（教程类标题、广告关键词）→ 未命中粗筛的文档按标题+来源+正文前 800 字调用文本大模型 → 解析 is_news/category/四条件/confidence/reason/evidence → 置信度<0.8 进复核；≥0.8 且非新闻跳过；≥0.8 且新闻继续下游。	meta_clean_slice 输出 records.jsonl（含 slices）	上游 records.jsonl（一文档一行）或该文件的 zip	records.jsonl（上游字段 + genre{is_news,category,conditions,confidence,reason,evidence,screening}）；review.jsonl；lineage_<run_id>.jsonl
3	META-OP-03	meta_fact_extract	新闻事实抽取	文本元信息	环节② 事实抽取	第3环	不可跳过（产线固定环节）	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	从新闻正文中抽取可审计的事实清单：数据来源类型、发布时间候选、人物/地点/组织实体（含原文短句与位置证据），同字段多候选保留并标记冲突，作为元信息补全的依据。	逐文档按切片并发抽取 → 每片输出 sourceType/timeCandidates/entities → 文档级合并去重 → 同字段多候选保留并标 conflict、跨片不一致记 uncertain → 计算 extractConfidence → 写 records/review/lineage。	meta_genre_judge 输出 records.jsonl（含 slices、genre）	上游 records.jsonl（新闻文档，含 slices 与 genre）	records.jsonl（上游字段 + facts{sourceType,timeCandidates[],entities[],conflicts[],uncertain[],extractConfidence}）；review.jsonl；lineage_<run_id>.jsonl
4	META-OP-04	meta_field_fill	元信息三组补全	文本元信息	环节③ 元信息补全	末位 · 第4环	不可跳过（产线固定环节）	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	基于标题、正文与事实清单，按三组 16 字段（结构化 4 + 基础 6 + 相关 6）做文档级元信息补全，逐字段输出 value 与 confidence，并生成一文档一行的数据集行。	读上游 records（含 facts）→ 标题 + 正文截断 6000 字 + 事实清单 → 一次调用补全 16 字段 → 字段校验（缺失兜底“无/不适用”、枚举纠正）→ 逐字段置信度汇总 → 写 records/fields_detail/review，isLastOperator 时收口阶段 zip。	meta_fact_extract 输出 records.jsonl（含 facts）	上游 records.jsonl（含事实清单）	records.jsonl（docId + structured 4 + basic 6 + related 6 + extractConfidence + fillConfidence + reviewStatus + revisionStatus）；fields_detail.jsonl；review.jsonl；<run_id>_stage_output.zip（isLastOperator=true）
5	LAY-OP-01	lay_page_render	版面分页渲染	复杂版面	环节① 文档接入与分页	阶段首 · 第1环	不可跳过（产线固定环节）	规则型	无（PyMuPDF）	否	把 PDF 打开校验后逐页渲染为页图，生成含 docId、pageCount、format、pageRange、checksum 的页清单与失败页清单，为逐页版面检测提供底图。	打开 PDF 校验加密/损坏/0 页 → 逐页 pixmap 渲染（默认 150 DPI）→ 生成 PageManifest 与 pages[] → 单页渲染失败隔离进 failedPages → 写 records.jsonl 与血缘。	平台 uploadFile 上传 PDF 素材 zip；predict 传 uniqueId	PDF 文件（zip 或散文件，按文件名升序）	pages/<docId>/*.png；records.jsonl（manifest + pages[] + failedPages[]）；lineage_<uniqueId>.jsonl
6	LAY-OP-02	lay_page_detect	逐页版面检测	复杂版面	环节② 逐页检测 + 环节③ 质量校验汇总	末位 · 第2环	不可跳过（产线固定环节）	大模型（视觉）+ 规则分流	Qwen/Qwen3-VL-32B-Instruct	是	逐页识别版面元素（类型、bbox、页内阅读顺序、结构树、框选/判定置信度），生成框选可视化图层，按六类规则把问题页分流进复核，并汇总失败页与复核结论，形成一页一行的数据集行。	读上游 records + pages → 逐页并发 VL 调用（长边 1600px）→ 输出元素数组/结构树/阅读顺序/双置信度 → 后处理校验（坐标、IoU、越界、顺序）→ 六类规则分流 → 生成 visual 框选图层 → 汇总 failedPages 与 review，末位收口阶段 zip。	lay_page_render 输出 records.jsonl + pages/	上游 records.jsonl + pages/ 页图	records.jsonl（pageId/elementCount/elements[]/structureTree/readingOrder/confidence/lowConfidenceCount/lowConfidenceReasons/reviewStatus）；visual/*.png；review.jsonl；<run_id>_stage_output.zip
7	FML-OP-01	fml_formula_locate	公式区域定位与裁切	公式文本	环节① 素材接入与定位	阶段首 · 第1环	不可跳过（产线固定环节）	规则（PDF 渲染）+ 视觉大模型（grounding）	Qwen/Qwen3-VL-32B-Instruct	是	从混合文档 PDF 中定位独立成行或带编号的公式区域（行内公式不处理），按页裁切公式图并登记可回溯的公式实例（页码、bbox、上下文文本范围）。	上传 PDF → 逐页渲染 150 DPI → 逐页 VL grounding（并发 4-8）→ 坐标校验（0-1000、x1<x2<y1<y2、面积≥20）→ 按页图裁切 crops → 关联章节标题与上下文≤2000 字 → 写 records/lineage。	平台 uploadFile 上传 PDF 素材 zip；predict 传 uniqueId	PDF 文件（zip 或散文件，混合文档，含正文与公式）	crops/<docId>/<instanceId>.png；pages/<docId>/*.png；records.jsonl（FormulaInstance：pageNo/bbox/hasNumber/confidence/context）；lineage_<uniqueId>.jsonl
8	FML-OP-02	fml_formula_recognize	公式识别与结构化标注	公式文本	环节② 公式识别 + 环节③ 结构化标注	末位 · 第2环	不可跳过（产线固定环节）	视觉大模型 + 规则 LaTeX 校验 + 文本模型修复	Qwen/Qwen3-VL-32B-Instruct（识别）+ deepseek-ai/DeepSeek-V3.2（修复）	是	对公式裁切图一次调用输出 LaTeX、符号表（含义/单位）、章节上下文与识别/语义双置信度；LaTeX 语法非法时用文本模型只修语法不改内容，最终形成一个公式一行的数据集行。	读上游 records + crops → 逐实例 VL 调用（裁切图长边 1200px + 页号/bbox/章节/上下文）→ 解析 latex/symbols/context/双置信度 → 剥定界符、置信度截断 → LaTeX 语法规则校验 → 非法走修复 Prompt 复检 → 仍非法进复核 → 写 records/trace/review，末位收口。	fml_formula_locate 输出 records.jsonl + crops/	上游 records.jsonl + crops/ 公式裁切图	records.jsonl（一公式一行：instanceId/latex/symbols[]/context{chapter,number,definition}/recognitionConfidence/semanticConfidence/reviewStatus/revisionStatus）；trace.jsonl（pageNo/bbox/crop/chapterTitle/uncertain）；review.jsonl；<run_id>_stage_output.zip
9	IMG-OP-01	img_region_locate	图片区域定位与裁切	图文融合	环节① 图片接入与判型	阶段首 · 第1环	不可跳过（产线固定环节）	规则 / CV	无（Pillow）	否	校验图片可用性并定位内容区域：整图直通，若存在拍照黑边/扫描白边等均色边框则按四角背景色基准自动裁掉，登记 ImageRegion 供判型与描述消费。	逐图打开校验 → 四角采样均值作背景色 → 差分掩码求内容区 bbox → 无均色边框则整图直通，有边框则裁边 → 裁剪后任一边<32px 判异常并重试（共 3 次）→ 写 regions/records/lineage。	平台 uploadFile 上传图片素材 zip；predict 传 uniqueId	JPG/PNG/BMP/WebP/TIFF 图片（zip 或散文件，按文件名升序）	regions/<imageId>.png；records.jsonl（imageId/fileName/image/region{bbox,cropped,width,height,sourceWidth,sourceHeight}）；lineage_<uniqueId>.jsonl
10	IMG-OP-02	img_type_classify	图片判型	图文融合	环节① 图片接入与判型	第2环	不可跳过（产线固定环节）	大模型（视觉）	Qwen/Qwen3-VL-32B-Instruct	是	按任务大类（几何/统计/表格/示意）做图片判型：先校验与任务大类是否一致，不一致跳过；一致后判定子类、置信度与依据，是图文融合产线的分类闸。	读上游 records + regions → 逐图并发 VL 调用 → 解析 match/category/subtype/confidence/reason → 输出校验（枚举/布尔）→ 大类不一致 skip；一致则 imageType 并入 records 并复制图片；置信度<0.8 追加 review 仍进下游。	img_region_locate 输出 records.jsonl + regions/；任务参数 category 已选定	上游 records.jsonl + regions/ 图片；predict 必带 category（几何/统计/表格/示意）	records.jsonl（上游字段 + imageType{match,category,subtype,confidence,reason,taskCategory}）；regions/（匹配图片副本，输出自包含）；review.jsonl；lineage_<run_id>.jsonl
11	IMG-OP-03	img_struct_describe	图文要素与描述生成	图文融合	环节② 要素与结构提取 + 环节③ 描述生成	末位 · 第3环	不可跳过（产线固定环节）	视觉大模型 + 规则回核	Qwen/Qwen3-VL-32B-Instruct	是	按图片大类选择四套 Prompt 之一，一次调用完成 OCR/要素/结构提取与字段化描述生成，逐字段给置信度，并用规则回核描述中的数字是否在 OCR 文字中有依据，形成一张一行的数据集行。	读上游 records（含 imageType）→ 按 category 选 Prompt（几何 4 字段/统计 6 字段/表格 4 字段/示意 6 字段）→ 逐图并发 VL 调用 → 校验 type/subtype 与判型一致 → 字段缺失兜底“无”、置信度缺失记问题 → 计算 type/ocr/desc 三置信度 → 数字回核 OCR → 写 records/details/review，末位收口。	img_type_classify 输出 records.jsonl + regions/（含 imageType）	上游 records.jsonl + regions/ 图片（含判型结果）	records.jsonl（imageId/type/subtype/table/description/confidence{type,ocr,desc}/lowConfidenceCount/lowConfidenceReasons/reviewStatus）；details.jsonl（OCR 明细/fieldConfidence/结构要素/uncertain）；review.jsonl；<run_id>_stage_output.zip

序号	算子编号	算子ID（英文）	失败处理	结果路由	约束边界 / 边界确认	技术关键处理方案	关键参数（默认值）	实测单样本耗时	是否通用	版本/状态	依据文档/交付目录
1	META-OP-01	meta_clean_slice	解码/抽取失败、空白页、导航页、无有效段落 → skipped 并记录中文原因；单片失败不阻断同批其它样本。	skipped（不适用，不进下游）；当前实现无 review / failed 样本级产出。	只做抽取、校验、切片三件事；不改写正文、不做语言校验；新闻体裁校验由下游 meta_genre_judge 承担；切片 2000/200 为固定口径，不开放覆盖。	纯规则、零模型调用；空白判断 total_chars==0，导航页判断锚文本占比>0.6，有效段落阈值≥20 字；切片按章节→段落，相邻片重叠 200 字。	无（切片长度、重叠、校验阈值均固定）	5 篇 HTML < 0.1 s（纯 CPU）	通用	v1.0.0 · 已交付	文本元信息_交付说明_v3.md §三 环节①；operators/meta_clean_slice 说明书
2	META-OP-02	meta_genre_judge	规则粗筛命中直接判定，不调模型；模型输出解析失败 → review；置信度<0.8 → review（不论是否新闻）；≥0.8 非新闻 → skipped。	keep（新闻）/ skipped（非新闻）/ review（低置信、解析失败）；review 不进下游。	只做体裁判定，不做实体/时间抽取；规则粗筛只过滤明显非新闻，边界情形交模型；category 越权举兜底“其他”并保留原值，不因枚举违规重试。	规则粗筛 + 文本大模型 JSON mode；Prompt 为交付说明 §4.1 原文；置信度截断 [0,0.98]；temperature 0、超时 60s、传输重试 2 次、并发 4–8。	confidence_threshold=0.8；concurrency=4（上限 8）	单篇约 3–8 s；并发 4 时 4 篇约 10 s	不通用（新闻体裁口径）	v1.0.0 · 已交付	文本元信息_交付说明_v3.md §三 环节①、§四 4.1；operators/meta_genre_judge 说明书
3	META-OP-03	meta_fact_extract	来源类型缺失、候选冲突、抽取置信度<0.8、全部切片失败 → review；单片解析失败重试 1 次并记 uncertain；冲突不阻断，进复核由人裁定。	keep / review；review 继续下游（数据集行保留，reviewStatus=待复核）。	只抽文中明确出现的信息，不推断不补全；抽不到返回空数组不编造；切片只用于读，合并后交下游文档级补全。	按片并发调用文本大模型 JSON mode；规则合并去重；Prompt 为交付说明 §4.2 原文；置信度截断 [0,0.98]。	confidence_threshold=0.8；concurrency=4（上限 8）	单片约 3–8 s；2 篇（4 片）并发 4 约 15 s	通用（换 Prompt 可复用）	v1.0.0 · 已交付	文本元信息_交付说明_v3.md §三 环节②、§四 4.2；operators/meta_fact_extract 说明书
4	META-OP-04	meta_field_fill	字段缺失、枚举非法、置信度输出失败、fillConfidence<0.8 → review；JSON 解析失败重试 1 次，仍失败 → failed + review（不进数据集）。	keep / review / failed；review 保留数据集行，failed 出局。	结构化字段必须以事实清单为依据，不得编造；基础/相关字段可推理但必须给置信度；确实没有的字段写“无/不适用”，不留空不硬编；知识点少于 3 个按实际数量输出。	文档级一次调用（非逐片补全）；Prompt 为交付说明 §4.3 原文；max_tokens 8192；置信度截断 [0,0.98]。	confidence_threshold=0.8；max_text_chars=6000（≥500）；concurrency=4（上限 8）	单篇约 5–25 s；2 篇并发约 30 s	不通用（16 字段为新闻元信息口径）	v1.0.0 · 已交付	文本元信息_交付说明_v3.md §三 环节③、§四 4.3、§五；operators/meta_field_fill 说明书
5	LAY-OP-01	lay_page_render	整份加密/损坏/0 页/全部页失败 → failed（任务待处理口径）；单页渲染失败 → failedPages，跳过该页，不牵连整份。	keep / failed（整份出局）；failedPages 汇总后交下游检测算子，不送环节②。	只做渲染与清单，不做版面检测；单页失败隔离；DPI 默认 150（交付建议 150–200，接口允许 72–300）。	PyMuPDF pixmap 渲染；SHA-256 原文件 checksum；纯 CPU、零模型调用。	dpi=150（72–300）；image_format=png（可选 jpg）	3 页 PDF 约 1 s（150 DPI，纯 CPU）	通用	v1.0.0 · 已交付	复杂版面_交付说明_v5.md §三 环节①；operators/lay_page_render 说明书
6	LAY-OP-02	lay_page_detect	单页模型失败 → failed 页清单；输出非法重试 1 次，仍失败 → 失败页；六类规则命中 → review（只标记不裁决）；不中断同批其它页。	keep / review（问题页，继续下游，数据集行保留）/ failed（该页出局）；环节③只汇总不自检。	不做 OCR、不提取文字；只排本页阅读顺序；规则分流只标记不裁决；单页渲染失败由上游 failedPages 汇入；系统性错误重跑由平台侧作废旧复核单。	Qwen3-VL-32B 多模态调用；长边压 1600px（实测 2000px 超 60s、1600px 约 17s）；Prompt 为交付说明 §4.1/§4.2 原文；六类分流：框选<0.8、判定<0.8、重叠 IoU>0.3、越界、顺序重号/缺号、空页。	confidence_threshold=0.8；iou_threshold=0.3（固定口径，仅预留）；concurrency=4（上限 8）；draw_overlay=true	单页约 17 s；3 页并发 4 约 40 s	通用	v1.0.0 · 已交付	复杂版面_交付说明_v5.md §三 环节②③；operators/lay_page_detect 说明书
7	FML-OP-01	fml_formula_locate	单页定位失败 → 跳过该页并记录；坐标校验/裁切失败 → 跳过该实例并记录；整份 0 公式 → failed（任务待处理口径）。	keep / skipped（单页或单实例）/ failed（整份 0 公式）；跳过明细写血缘。	只处理独立成行或带编号公式，行内公式不处理；定位宁少勿多（漏检代价低于误检）；不做识别（环节②职责）。	PyMuPDF 渲染 + VL grounding；bbox 归一化 0–1000；输出非法重试 1 次；定位 Prompt 由本侧按环节①职责设计。	dpi=150（72–300）；max_context_chars=2000（≥200）；concurrency=4（上限 8）	单页定位约 10–20 s；2 页（1 页有公式）约 25 s	通用	v1.0.0 · 已交付	公式文本_交付说明_v2.md §三 环节①；operators/fml_formula_locate 说明书
8	FML-OP-02	fml_formula_recognize	JSON 不可解析或 latex 为空 → 重试 1 次，仍失败 → failed+review；LaTeX 语法非法 → 修复 Prompt，修复失败/复检仍非法 → review（原值保留）；符号缺失/定义无法定位/置信度<0.8 → review。	keep / review（继续下游，数据集行保留）/ failed（识别失败出局）；含义或单位为 null 不算失败。	②③是逻辑环节，不是两次模型调用；修复只修语法不改内容；回溯信息不进数据集；渲染回比不一致由平台复核环节承担。	Qwen3-VL-32B 识别 + DeepSeek-V3.2 修复；LaTeX 语法检查覆盖空/括号/环境/left-right/残留定界符；Prompt 为交付说明 §4.2/§4.3/§4.5 原文。	confidence_threshold=0.8（两分数共用）；concurrency=4（上限 8）	单公式约 10–25 s；修复加 3–8 s；3 实例并发 4 约 60 s	通用	v1.0.0 · 已交付	公式文本_交付说明_v2.md §三 环节②③、§四；operators/fml_formula_recognize 说明书
9	IMG-OP-01	img_region_locate	打开/解码失败、裁剪后过小 → 重试 2 次（共 3 次）仍失败 → skipped 并记录“区域定位失败”；单图失败不阻断同批。	keep / skipped（区域定位失败，不进下游）。	交付说明未给“区域”语义（Q1 待确认），当前按整图直通 + 均色边框裁剪实现；不做目标检测、不做主体分割、不增强像素。	Pillow 四角背景色差分掩码；border_tolerance 默认 18（0–255）；min_crop_size 默认 32px；纯确定性 CV、零模型调用。	border_tolerance=18（0–255）；min_crop_size=32（px）	5 张图 < 1 s（纯 CPU）	通用	v1.0.0 · 已交付	图文融合_交付说明_v3.md §三 环节①；operators/img_region_locate 说明书；README Q1
10	IMG-OP-02	img_type_classify	category 缺失/非法 → predict 整体 code=1；输出非法 → 重试 1 次，仍失败 → failed+review；大类不一致 → skipped；判型置信度<0.8 → review（不阻断）。	keep / skipped（大类不一致）/ review（低置信，继续下游）/ failed（输出持续非法）。	只做判型，不做要素提取与描述；子类只能从给定列表选；大类不一致不进入下游；判型模型与任务大类口径需一致。	Qwen3-VL-32B 多模态；Prompt 为交付说明 §4.3.1 原文；公共约定 §4.3.0 并入 System；置信度截断 [0,0.98]。	category 必填（几何/统计/表格/示意）；confidence_threshold=0.8；concurrency=4（上限 8）	单张约 8–15 s；5 张并发 4 约 20 s	通用（枚举可配置）	v1.0.0 · 已交付	图文融合_交付说明_v3.md §三 环节①、§四 4.3.1；operators/img_type_classify 说明书
11	IMG-OP-03	img_struct_describe	type/subtype 与判型不一致 → 重试 1 次，仍失败 → failed+review；描述缺字段、字段置信度缺失、回核无依据、三类低置信 → review；数值缺失写 null 不估算。	keep / review（继续下游）/ failed（生成失败出局）；“无/不适用”是合法值，不算失败。	提取文字必须与 OCR 一致；不做证明推理（几何）、不猜色值（示意）；描述字段缺失进复核；回核只校验数字来源，不改写描述。	Qwen3-VL-32B + 四套大类 Prompt（交付说明 §4.3.2–§4.3.5）；回核规则：描述中数字逐一在 OCR 文字找依据；置信度截断 [0,0.98]。	confidence_threshold=0.8（判型/OCR/描述三分共用）；concurrency=4（上限 8）	单张约 10–20 s；2 张并发约 25 s	通用（四套 Prompt 可按域扩展）	v1.0.0 · 已交付	图文融合_交付说明_v3.md §三 环节②③、§四 4.3.2–4.3.5；operators/img_struct_describe 说明书

文本元信息产线 · 算子清单

链路：meta_clean_slice → meta_genre_judge → meta_fact_extract → meta_field_fill【末位收口】

序号	环节	链路位置	流程是否可跳过	算子编号	算子ID	算子名称	工具类型	基座模型	调外部API	能力说明	输入数据	输出数据	失败处理	结果路由	关键参数	是否通用	版本/状态
1	环节① 文档接入与切片	阶段首 · 第1环	不可跳过（产线固定环节）	META-OP-01	meta_clean_slice	正文抽取与切片	规则型	无（标准库 HTMLParser + 正则）	否	把网页存档 HTML 抽取为标题、来源与正文，完成正文有效性校验后按章节→段落切片（单片≤2000字、重叠200字），形成一文档一行的结构化记录，供体裁判定与事实抽取消费。	HTML/HTM 文件（zip 或散文件，按文件名升序）；单批 ≤2GB	records.jsonl（docId/fileName/title/source/textLength/sliceCount/slices[{sliceId,index,text,charCount}]）；lineage_<uniqueId>.jsonl	解码/抽取失败、空白页、导航页、无有效段落 → skipped 并记录中文原因；单片失败不阻断同批其它样本。	skipped（不适用，不进下游）；当前实现无 review / failed 样本级产出。	无（切片长度、重叠、校验阈值均固定）	通用	v1.0.0 · 已交付
2	环节① 文档接入与切片（体裁校验）	第2环	不可跳过（产线固定环节）	META-OP-02	meta_genre_judge	新闻体裁判定	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	对上游正文做新闻体裁校验：按事件性、时效性、事实性、公共传播性四条标准判定是否新闻，输出体裁类别、四条件、置信度与依据；非新闻在此出局，是文本元信息产线的总闸。	上游 records.jsonl（一文档一行）或该文件的 zip	records.jsonl（上游字段 + genre{is_news,category,conditions,confidence,reason,evidence,screening}）；review.jsonl；lineage_<run_id>.jsonl	规则粗筛命中直接判定，不调模型；模型输出解析失败 → review；置信度<0.8 → review（不论是否新闻）；≥0.8 非新闻 → skipped。	keep（新闻）/ skipped（非新闻）/ review（低置信、解析失败）；review 不进下游。	confidence_threshold=0.8；concurrency=4（上限 8）	不通用（新闻体裁口径）	v1.0.0 · 已交付
3	环节② 事实抽取	第3环	不可跳过（产线固定环节）	META-OP-03	meta_fact_extract	新闻事实抽取	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	从新闻正文中抽取可审计的事实清单：数据来源类型、发布时间候选、人物/地点/组织实体（含原文短句与位置证据），同字段多候选保留并标记冲突，作为元信息补全的依据。	上游 records.jsonl（新闻文档，含 slices 与 genre）	records.jsonl（上游字段 + facts{sourceType,timeCandidates[],entities[],conflicts[],uncertain[],extractConfidence}）；review.jsonl；lineage_<run_id>.jsonl	来源类型缺失、候选冲突、抽取置信度<0.8、全部切片失败 → review；单片解析失败重试 1 次并记 uncertain；冲突不阻断，进复核由人裁定。	keep / review：review 继续下游（数据集行保留，reviewStatus=待复核）。	confidence_threshold=0.8；concurrency=4（上限 8）	通用（换 Prompt 可复用）	v1.0.0 · 已交付
4	环节③ 元信息补全	末位 · 第4环	不可跳过（产线固定环节）	META-OP-04	meta_field_fill	元信息三组补全	大模型（文本）	deepseek-ai/DeepSeek-V3.2	是	基于标题、正文与事实清单，按三组 16 字段（结构化 4 + 基础 6 + 相关 6）做文档级元信息补全，逐字段输出 value 与 confidence，并生成一文档一行的数据集行。	上游 records.jsonl（含事实清单）	records.jsonl（docId + structured 4 + basic 6 + related 6 + extractConfidence + fillConfidence + reviewStatus + revisionStatus）；fields_detail.jsonl；review.jsonl；<run_id>_stage_output.zip（isLastOperator=true）	字段缺失、枚举非法、置信度输出失败、fillConfidence<0.8 → review；JSON 解析失败重试 1 次，仍失败 → failed + review（不进数据集）。	keep / review / failed：review 保留数据集行，failed 出局。	confidence_threshold=0.8；max_text_chars=6000（≥500）；concurrency=4（上限 8）	不通用（16 字段为新闻元信息口径）	v1.0.0 · 已交付

复杂版面产线 • 算子清单

链路：lay_page_render → lay_page_detect【末位收口】

序号	环节	链路位置	流程是否可跳过	算子编号	算子ID	算子名称	工具类型	基座模型	调外部API	能力说明	输入数据	输出数据	失败处理	结果路由	关键参数	是否通用	版本/状态
1	环节① 文档接入与分页	阶段首 • 第1环	不可跳过（产线固定环节）	LAY-OP-01	lay_page_render	版面分页渲染	规则型	无（PyMuPDF）	否	把 PDF 打开校验后逐页渲染为页图，生成含 docId、pageCount、format、pageRange、checksum 的页清单与失败页清单，为逐页版面检测提供底图。	PDF 文件（zip 或散文件，按文件名升序）	pages/<docId>/*.png；records.jsonl（manifest + pages[] + failedPages[]）；lineage_<uniqueId>.jsonl	整份加密/损坏/0 页/全部页失败 → failed（任务待处理口径）；单页渲染失败 → failedPages，跳过该页，不牵连整份。	keep / failed（整份出局）；failedPages 汇总后交下游检测算子，不送环节②。	dpi=150（72–300）；image_format=png（可选 jpg）	通用	v1.0.0 • 已交付
2	环节② 逐页检测 + 环节③ 质量校验汇总	末位 • 第2环	不可跳过（产线固定环节）	LAY-OP-02	lay_page_detect	逐页版面检测	大模型（视觉）+ 规则分流	Qwen/Qwen3-VL-32B-Instruct	是	逐页识别版面元素（类型、bbox、页内阅读顺序、结构树、框选/判定置信度），生成框选可视化图层，按六类规则把问题页分流进复核，并汇总失败页与复核结论，形成一页一行的数据集行。	上游 records.jsonl + pages/ 页图	records.jsonl（pageId/elementCount/elements[]/structureTree/readingOrder/confidence/lowConfidenceCount/lowConfidenceReasons/reviewStatus）；visual/*.png；review.jsonl；<run_id>_stage_output.zip	单页模型失败 → failed 页清单；输出非法重试 1 次，仍失败 → 失败页；六类规则命中 → review（只标记不裁决）；不中断同批其它页。	keep / review（问题页，继续下游，数据集行保留）/ failed（该页出局）；环节③只汇总不自检。	confidence_threshold=0.8；iou_threshold=0.3（固定口径，仅预留）；concurrency=4（上限 8）；draw_overlay=true	通用	v1.0.0 • 已交付

公式文本产线 • 算子清单

链路：fml_formula_locate → fml_formula_recognize【末位收口】

序号	环节	链路位置	流程是否可跳过	算子编号	算子ID	算子名称	工具类型	基座模型	调外部API	能力说明	输入数据	输出数据	失败处理	结果路由	关键参数	是否通用	版本/状态
1	环节① 素材接入与定位	阶段首 • 第1环	不可跳过（产线固定环节）	FML-OP-01	fml_formula_locate	公式区域定位与裁切	规则（PDF 渲染）+ 视觉大模型（grounding）	Qwen/Qwen3-VL-32B-Instruct	是	从混合文档 PDF 中定位独立成行或带编号的公式区域（行内公式不处理），按页裁切公式图并登记可回溯的公式实例（页码、bbox、上下文文本范围）。	PDF 文件（zip 或散文件，混合文档，含正文与公式）	crops/<docId>/<instanceId>.png；pages/<docId>/*.png；records.jsonl（FormulaInstance：pageNo/bbox/hasNumber/confidence/context）；lineage_<uniqueId>.jsonl	单页定位失败 → 跳过该页并记录：坐标校验/裁切失败 → 跳过该实例并记录：整份 0 公式 → failed（任务待处理口径）。	keep / skipped（单页或单实例）/ failed（整份 0 公式）：跳过明细写血缘。	dpi=150（72–300）；max_context_chars=2000（≥200）；concurrency=4（上限 8）	通用	v1.0.0 • 已交付
2	环节② 公式识别 + 环节③ 结构化标注	末位 • 第2环	不可跳过（产线固定环节）	FML-OP-02	fml_formula_recognize	公式识别与结构化标注	视觉大模型 + 规则 LaTeX 校验 + 文本模型修复	Qwen/Qwen3-VL-32B-Instruct（识别）+ deepseek-ai/DeepSeek-V3.2（修复）	是	对公式裁切图一次调用输出 LaTeX、符号表（含义/单位）、章节上下文与识别/语义双置信度；LaTeX 语法非法时用文本模型只修语法不改内容，最终形成一个公式一行的数据集行。	上游 records.jsonl + crops/ 公式裁切图	records.jsonl（一公式一行：instanceId/latex/symbols[]/context{chapter,number,definition}/recognitionConfidence/semanticConfidence/reviewStatus/revisionStatus）；trace.jsonl（pageNo/bbox/crop/chapterTitle/uncertain）；review.jsonl；<run_id>_stage_output.zip	JSON 不可解析或 latex 为空 → 重试 1 次，仍失败 → failed+review；LaTeX 语法非法 → 修复 Prompt，修复失败/复检仍非法 → review（原值保留）；符号缺失/定义无法定位/置信度<0.8 → review。	keep / review（继续下游，数据集行保留）/ failed（识别失败出局）；含义或单位为 null 不算失败。	confidence_threshold=0.8（两分数共用）；concurrency=4（上限 8）	通用	v1.0.0 • 已交付

图文融合产线 · 算子清单

链路：img_region_locate → img_type_classify → img_struct_describe【末位收口】

序号	环节	链路位置	流程是否可跳过	算子编号	算子ID	算子名称	工具类型	基座模型	调外部API	能力说明	输入数据	输出数据	失败处理	结果路由	关键参数	是否通用	版本/状态
1	环节① 图片接入与判型	阶段首 · 第1环	不可跳过（产线固定环节）	IMG-OP-01	img_region_locate	图片区域定位与裁切	规则 / CV	无（Pillow）	否	校验图片可用性并定位内容区域：整图直通，若存在拍照黑边/扫描白边等均色边框则按四角背景色基准自动裁掉，登记 ImageRegion 供判型与描述消费。	JPG/PNG/BMP/WebP/TIFF 图片（zip 或散文件，按文件名升序）	regions/<imageId>.png；records.jsonl（imageId/fileName/image/region{bbox,cropped,width,height,sourceWidth,sourceHeight}）；lineage_<uniqueId>.jsonl	打开/解码失败、裁剪后过小 → 重试 2 次（共 3 次）仍失败 → skipped 并记录“区域定位失败”；单图失败不阻断同批。	keep / skipped（区域定位失败，不进下游）。	border_tolerance=18（0–255）；min_crop_size=32（px）	通用	v1.0.0 · 已交付
2	环节① 图片接入与判型	第2环	不可跳过（产线固定环节）	IMG-OP-02	img_type_classify	图片判型	大模型（视觉）	Qwen/Qwen3-VL-32B-Instruct	是	按任务大类（几何/统计/表格/示意）做图片判型：先校验与任务大类是否一致，不一致跳过；一致后判定子类、置信度与依据，是图文融合产线的分类闸。	上游 records.jsonl + regions/ 图片；predict 必带 category（几何/统计/表格/示意）	records.jsonl（上游字段 + imageType{match,category,subtype,confidence,reason,taskCategory}）；regions/（匹配图片副本，输出自包含）；review.jsonl；lineage_<run_id>.jsonl	category 缺失/非法 → predict 整体 code=1；输出非法 → 重试 1 次，仍失败 → failed+review；大类不一致 → skipped；判型置信度<0.8 → review（不阻断）。	keep / skipped（大类不一致）/ review（低置信，继续下游）/ failed（输出持续非法）。	category 必填（几何/统计/表格/示意）；confidence_threshold=0.8；concurrency=4（上限 8）	通用（枚举可配置）	v1.0.0 · 已交付
3	环节② 要素与结构提取 + 环节③ 描述生成	末位 · 第3环	不可跳过（产线固定环节）	IMG-OP-03	img_struct_describe	图文要素与描述生成	视觉大模型 + 规则回核	Qwen/Qwen3-VL-32B-Instruct	是	按图片大类选择四套 Prompt 之一，一次调用完成 OCR/要素/结构提取与字段化描述生成，逐字段给置信度，并用规则回核描述中的数字是否在 OCR 文字中有依据，形成一张一行的数据集行。	上游 records.jsonl + regions/ 图片（含判型结果）	records.jsonl（imageId/type/subtype/table/description/confidence{type,ocr,desc}/lowConfidenceCount/lowConfidenceReasons/reviewStatus）；details.jsonl（OCR 明细/fieldConfidence/结构要素/uncertain）；review.jsonl；<run_id>_stage_output.zip	type/subtype 与判型不一致 → 重试 1 次，仍失败 → failed+review；描述缺字段、字段置信度缺失、回核无依据、三类低置信 → review；数值缺失写 null 不估算。	keep / review（继续下游）/ failed（生成失败出局）；“无/不适用”是合法值，不算失败。	confidence_threshold=0.8（判型/OCR/描述三分共用）；concurrency=4（上限 8）	通用（四套 Prompt 可按域扩展）	v1.0.0 · 已交付

算子ID	参数	类型	默认值	取值范围/说明	任务级可调
meta_clean_slice	—	—	无	切片 2000/200、空白/导航/段落校验阈值全部固定	否
meta_genre_judge	confidence_threshold	Number	0.8	体裁判定置信度阈值；低于进复核	是
meta_genre_judge	concurrency	Number	4	模型调用并发，上限 8	否（性能参数）
meta_fact_extract	confidence_threshold	Number	0.8	抽取质量阈值；低于进复核	是
meta_fact_extract	concurrency	Number	4	模型调用并发，上限 8	否（性能参数）
meta_field_fill	confidence_threshold	Number	0.8	补全质量阈值；fillConfidence 低于进复核	是
meta_field_fill	max_text_chars	Number	6000	送模型的正文最大字符，须 ≥500	是
meta_field_fill	concurrency	Number	4	模型调用并发，上限 8	否（性能参数）
lay_page_render	dpi	Number	150	渲染 DPI，72–300（交付建议 150–200）	是
lay_page_render	image_format	String	png	页图格式，可选 jpg	是
lay_page_detect	confidence_threshold	Number	0.8	框选/判定共用低置信阈值	是
lay_page_detect	iou_threshold	Number	0.3	重叠判定 IoU 阈值（固定口径，仅预留）	否
lay_page_detect	concurrency	Number	4	逐页调用并发，上限 8	否（性能参数）
lay_page_detect	draw_overlay	Boolean	true	是否生成框选可视化图层	是
fml_formula_locate	dpi	Number	150	页图渲染 DPI，72–300	是
fml_formula_locate	max_context_chars	Number	2000	上下文文本上限，须 ≥200（固定口径，仅预留）	否
fml_formula_locate	concurrency	Number	4	逐页定位并发，上限 8	否（性能参数）
fml_formula_recognize	confidence_threshold	Number	0.8	识别/语义双分数共用阈值	是
fml_formula_recognize	concurrency	Number	4	逐实例调用并发，上限 8	否（性能参数）

算子ID	参数	类型	默认值	取值范围/说明	任务级可调
img_region_locate	border_tolerance	Number	18	边框判定容差 0–255；差异低于容差视为背景	是
img_region_locate	min_crop_size	Number	32	裁剪后最小保留边长（px）；过小判异常	是
img_type_classify	category	String	必填	任务大类：几何 / 统计 / 表格 / 示意	是（任务级必填）
img_type_classify	confidence_threshold	Number	0.8	判型置信度阈值；低于进复核不阻断	是
img_type_classify	concurrency	Number	4	逐图调用并发，上限 8	否（性能参数）
img_struct_describe	confidence_threshold	Number	0.8	判型/OCR/描述三分共用阈值	是
img_struct_describe	concurrency	Number	4	逐图调用并发，上限 8	否（性能参数）

文本定制化生产 • 算子清单（v2）

生成日期	2026-11-03
版本说明	v2 修正 v1 的四处问题：四张产线分表序号各自从 1 重置；补全 img_type_classify 被截断的 lineage 输出；总表改 A3 横向分 2 页宽打印；说明页去掉空行，打开默认定位总表。
覆盖范围	4 条产线、11 个算子服务（算法侧已交付）。本清单只列算子侧；平台前后端、素材管理、条件复核、数据集归集另见研发对齐文档，不在本表展开。
格式参考	E:\HYQX\后训练系统\正式版开发\00-总表与任务书\【工具清单】0912 后训练4条产线流程实施方案设计V2.xlsx
与参考表差异	参考表的 FGW任务书原文 / COSMIC功能点原文 / 负责人 / 交付时间节点 属后训练项目口径，本项目无对应来源，未列；改以“依据文档/交付目录”标注交付说明章节与算子目录。
主要依据	operators/README.md；operators/前后端对接说明.md；四份交付说明（文本元信息 v3 / 复杂版面 v5 / 公式文本 v2 / 图文融合 v3）；11 份算子说明书与测试指令。
算子编号规则	META / LAY / FML / IMG = 产线短名；OP = Operator；末两位 = 链路顺序。算子ID 为目录名与 map.json 键，跨系统唯一。
序号口径	“算子总表”用全局序号 1–11；四张产线分表各自从 1 重新编号，便于按产线单独使用。
算子形态	每个算子 = 独立可部署服务（FastAPI + uvicorn，容器内端口 6288；宿主机 6301–6311），三接口一致：/healthz、/uploadFile、/removeFile、/predict。
宿主机端口	6301 meta_clean_slice | 6302 meta_genre_judge | 6303 meta_fact_extract | 6304 meta_field_fill | 6305 lay_page_render | 6306 lay_page_detect | 6307 fml_formula_locate | 6308 fml_formula_recognize | 6309 img_region_locate | 6310 img_type_classify | 6311 img_struct_describe
素材白名单	文本元信息 HTML/HTM/ZIP；复杂版面 PDF/ZIP；公式文本 PDF/ZIP；图文融合 JPG/PNG/BMP/WebP/TIFF/ZIP。素材由平台按算子要求打 zip 后 uploadFile。
链路编排	阶段首凭 uniqueId 取素材；中段用 inputFile 接续上一跳 outputFile；末位 isLastOperator=true 收口为阶段 zip。
结果路由	skipped = 素材不适用，不进下游；review = 低置信/冲突/非法输出，数据集行保留、继续下游、待人工复核；failed = 处理失败，该样本出局。

文本定制化生产 • 算子清单（v2）

模型接入	统一走硅基流动（OpenAI 兼容）：视觉 Qwen/Qwen3-VL-32B-Instruct，文本 deepseek-ai/DeepSeek-V3.2；8 个算子调外部 API，3 个纯规则/CV 不调模型。
统一调用约定	temperature 0；超时 60 s；传输层重试 2 次（最多 3 次）；JSON-only 输出；算子内并发 4–8；输出非法算子内重试 1 次；置信度统一截断 [0,0.98]。
完成状态口径	11 个算子均为 v1.0.0 已交付（算法实现 + HTTP 接口 + Docker 部署件 + 样本 + 单测 + 说明书/测试指令）；release/ 下为 11 个交付 zip。
“是否通用”口径	“通用”指换 Prompt / 枚举 / 字段配置可迁同类业务；“不通用”指与新闻体裁/16 字段口径强绑定。
已知待确认 Q1	图文融合①“区域定位”语义未给原型；当前按“整图直通 + 均色边框自动裁剪”实现。
已知待确认 Q2	算子说明书当前交付 md；如甲方要求 docx，可另行转换，不影响算子实现。
已知待确认 Q3	置信度阈值默认 0.8 尚未用真实样本校准；模型自评分仅作相对高低，阈值需按真实分布标定。
维护提示	新增/变更算子时，同步更新本清单、算子说明书、前后端对接说明与 release 交付包；阈值/Prompt 变更须留版本记录。